

Invariância a Translação na Super-Resolução por Tiles: Análise do Gerador Satlas e Estratégia Ótima de Junção

Marcel Fernandes Gomes
Programa de Pós-Graduação em Computação
Universidade Federal do Rio Grande do Sul
Porto Alegre, Brasil
marcelgfernandes@gmail.com

Resumo—Modelos de super-resolução (SR) de imagens de satélite são aplicados, em grandes áreas, por inferência em *tiles* de tamanho fixo, mas com posição arbitrária. Se o gerador fosse perfeitamente equivariante a translação, deslocar o conteúdo físico dentro do tile deveria apenas deslocar a saída, sem alterar os valores na região sobreposta entre duas inferências. Neste trabalho medimos empiricamente quanto essa propriedade se quebra no gerador ESRGAN/SSR_RRDBNet do Satlas, em modo *zero-shot* (pesos pré-treinados, sem retreino), sobre imagens Sentinel-2. Comparando a saída SR do mesmo conteúdo com o tile deslocado por inteiros de pixel em baixa resolução (LR), quantificamos a discordância na sobreposição por uma métrica de auto-consistência (*shift-consistency* PSNR/SSIM), que dispensa verdade de campo. O protocolo, validado inicialmente em uma única região, foi estendido a 57 regiões geograficamente distintas do Sul do Brasil, agregando os resultados de forma *pooled* (média entre regiões). Observamos que a discordância é significativa e cresce *monotonicamente* à medida que a sobreposição se aproxima da borda do tile: o PSNR de auto-consistência cai de 30,8 dB (90% de sobreposição) para 24,7 dB (3%), e o SSIM de 0,85 para 0,45, com baixa dispersão entre regiões ($\pm 1,2$ dB). Um perfil de erro em função da distância à borda localiza a causa: a diferença média decai de 10,1 DN na borda para $\sim 2,0$ DN no interior, coerente com um campo receptivo que excede o tile somado ao *zero-padding*. A partir desse perfil derivamos máscaras de junção e comparamos estratégias de *blend*; entre as clássicas, a gaussiana reduz o excesso de gradiente nas costuras de 1,30 para 1,05 (ideal 1,0) e eleva o PSNR de referência de 25,3 para 34,4 dB, e estratégias adicionais (Poisson com Dirichlet, data-driven suavizado) chegam a superá-la. Os resultados quantificam a quebra de equivariância formal das CNNs em um gerador de SR real, mostram que o achado é robusto entre regiões e fornecem uma recomendação prática de montagem de mosaicos sem costura.

Index Terms—super-resolução, invariância a translação, equivariância, ESRGAN, junção de tiles, blending, Sentinel-2, sensoriamento remoto

I. INTRODUÇÃO

A super-resolução (SR) por aprendizado profundo tornou-se ferramenta padrão para ampliar a resolução efetiva de imagens de satélite, viabilizando a extração de feições finas (bordas de campos agrícolas, corpos d'água pequenos, estradas vicinais) a partir de sensores de resolução moderada como o Sentinel-2 (~ 10 m/px) [7]. Em aplicações reais sobre grandes áreas, a

inferência é feita por *tiles*: a cena é fatiada em janelas de tamanho fixo, cada janela é super-resolvida independentemente e as saídas são remontadas em um mosaico.

Esse procedimento expõe uma tensão pouco discutida. O modelo é treinado e avaliado em tiles de tamanho fixo, mas *não fixa a posição* do tile sobre o terreno — a grade de fatiamento é arbitrária. Surge então a pergunta de pesquisa central: **o gerador é invariante a translação?** Se fosse, dois tiles que cobrem a mesma porção física do terreno, porém deslocados entre si, deveriam produzir exatamente os mesmos pixels na região que compartilham. Onde isso falha, a remontagem produz *artefatos de costura* nas junções entre tiles.

Camadas convolucionais são, por construção, equivariantes a translação; CNNs completas, porém, não são estritamente invariantes, por causa de *padding* e subamostragem [4]. Este trabalho é uma verificação empírica direta dessa ressalva em um gerador de SR de produção. Nossas contribuições são:

- um **protocolo de medida de *shift-consistency* sem verdade de campo**, baseado na auto-consistência entre duas inferências do mesmo conteúdo com o tile deslocado por inteiros de pixel LR;
- um **diagnóstico do efeito de borda** — um perfil de erro em função da distância à borda do tile — que localiza a não-invariância e a atribui ao campo receptivo que excede o tile somado ao *zero-padding*;
- uma **estratégia de junção guiada pelos dados** e a comparação com *blends* usuais por uma métrica de costura.

O escopo é restrito ao Sentinel-2, domínio de treino do Satlas [2], para evitar o confundimento de *domain shift* multi-sensor. Trata-se de um estudo *zero-shot* (sem retreino). O protocolo foi validado primeiro em uma *única região* e, em seguida, **estendido a 57 regiões** geograficamente distintas; os resultados reportados são *pooled* (agregados entre regiões), o que permite avaliar a **robustez** do achado e sua dispersão entre áreas.

II. DESCRIÇÃO DO PROBLEMA

A. Super-resolução por tiles e invariância a translação

O gerador do Satlas é *multi-frame*: recebe N imagens LR da mesma região, em datas distintas, empilhadas como entrada de $3N$ canais em uma janela 32×32 , e produz uma única saída em alta resolução (HR) 128×128 , com fator $s = 4$, explorando informação sub-pixel entre as datas. Denotando por f o gerador e por T_Δ um operador de translação por Δ pixels, a **equivariância a translação** ideal exige

$$f(T_\Delta x) = T_{s\Delta} f(x), \quad (1)$$

isto é, deslocar a entrada de Δ pixels LR deveria deslocar a saída de $s\Delta$ pixels HR *sem alterar os valores*. Na região Ω comum a duas inferências deslocadas, os pixels físicos são os mesmos; sob (1), as duas saídas coincidiriam em Ω . A discordância observada mede o quanto f se afasta da equivariância formal das suas camadas convolucionais [4].

B. Fontes de não-invariância no Satlas

Identificamos as fontes e controlamos os confundimentos:

- **Campo receptivo $\gg$ tile.** O RRDBNet tem 23 blocos RRDB (~ 350 convoluções 3×3 com *padding* “same”), gerando um campo receptivo da ordem de centenas de pixels LR — muito maior que o tile 32×32 . *Todo* pixel de saída “enxerga” a borda do tile e o *zero-padding* associado; não existe interior verdadeiramente limpo. É a causa principal sob teste.
- **Upsampling nearest $\times 4$.** A interpolação por vizinho mais próximo é equivariante para deslocamentos *inteiros* em LR ($\Delta \rightarrow s\Delta$ exato). Por isso *todos* os deslocamentos do experimento são inteiros em pixels LR: assim o grid HR alinha sem reamostragem e o *upsampling* é removido como fonte de erro.
- **Seleção de frames.** A escolha de quais cenas usar é fixada *globalmente* (uma vez, deterministicamente, pelo critério de menor fração de *nodata*), de modo que toda posição usa exatamente os mesmos frames; caso contrário, a diferença viria da *entrada*, não do modelo.

III. SOLUÇÃO PROPOSTA

A. Arquitetura base (ESRGAN/RRDBNet)

Usamos o gerador ESRGAN [1] na variante SSR_RRDBNet do Satlas-SR [3] — modelo treinado sobre o conjunto SatlasPretrain [2] —, com os pesos públicos `esrgan_8S2.pth` ($N = 8$ frames). **Não há retreino**: todo o estudo é *zero-shot*. A perda original de treino, reproduzida aqui apenas como contexto, combina termo de pixel, perceptual e adversarial,

$$\mathcal{L} = \mathcal{L}_{pix} + \lambda_p \mathcal{L}_{perc} + \lambda_a \mathcal{L}_{adv}. \quad (2)$$

O termo perceptual [6] e o adversarial favorecem texturas plausíveis, mas não impõem qualquer restrição de consistência entre posições de tile — o que motiva o diagnóstico deste trabalho.

B. Protocolo de medida da invariância

Constrói-se uma vez o *stack* LR fixo, reprojetando as N cenas para um único grid comum (EPSG:3857 a 9,555 m/px) para garantir alinhamento pixel-a-pixel. Selecionam-se âncoras interiores sem *nodata*. Para cada âncora e cada deslocamento horizontal Δ , roda-se SR no *offset* 0 e no *offset* Δ ; como Δ pixels LR correspondem a $s\Delta$ pixels HR exatos, a sobreposição Ω contém os *mesmos pixels físicos*. A discordância é medida pelo PSNR de auto-consistência,

$$\text{scPSNR}(\Delta) = 10 \log_{10} \frac{255^2}{\text{MSE}(I_0^{SR}|_\Omega, I_\Delta^{SR}|_\Omega)}, \quad (3)$$

reportando-se também SSIM [5], MAE e RMSE em Ω . Varia-se a sobreposição de 100% ($\Delta = 0$, controle, em que Ω é o tile inteiro e a discordância deve ser nula) até $\sim 3\%$ ($\Delta = 31$).

C. Perfil de borda e blend ótimo

Para localizar a não-invariância, acumula-se a diferença absoluta média por coluna de Ω em função da distância d à borda de tile mais próxima, formando o perfil $P(d)$. Esse perfil mede a confiabilidade local da saída: quanto maior $P(d)$, menos confiável aquele pixel para a junção. Define-se então uma máscara de peso *data-driven* $w(d) \propto 1/P(d)$ e comparam-se as estratégias *none*, *linear*, *cosine*, *gaussian* e *data* na montagem de um mosaico real. A qualidade da costura é medida por

$$\text{seam_excess} = \frac{\text{gradiente médio nas linhas de junção}}{\text{gradiente médio global}}, \quad (4)$$

cujo valor ideal é ≈ 1 (a junção não se distingue do conteúdo); complementa-se com PSNR/SSIM contra um mosaico de referência por recorte central.

IV. RESULTADOS EXPERIMENTAIS

A. Configuração

Inferência *zero-shot* com `esrgan_8S2.pth` (sem retreino) em GPU Tesla V100-PCIE-32GB.¹ O protocolo foi validado primeiro em uma **região-piloto** (tile MGRS T22JDM, Sul do Brasil; 8 cenas Sentinel-2 TCI, datas entre 2025-10-10 e 2026-05-03) e, em seguida, **estendido a 57 regiões** geograficamente distintas, cada uma com 8 cenas Sentinel-2 TCI (produto RGB, 10 m) recortadas a uma AOI vetorial e reprojetadas a um grid comum a 9,555 m/px. Parâmetros por região: `tile= 32`, $s = 4$, $N = 8$, âncoras interiores sem *nodata* e $\Delta \in \{0, 3, 6, 10, 13, 16, 19, 22, 26, 29, 31\}$ px LR (sobreposição de 100% a 3,1%). Os resultados a seguir são *pooled* — a média entre as 57 regiões — com a dispersão (desvio-padrão) entre regiões reportada quando relevante. Esse desenho amplia substancialmente a quantidade de dados em relação à validação de região única inicial e permite aferir a robustez do achado.

¹**Reprodutibilidade.** Código dos experimentos, metadados das cenas (proveniência), AOIs vetoriais e todos os resultados (CSV e figuras) estão em https://github.com/MarcelFernandesCGEO/cmp620_trabalho_final. Pesos e código do gerador: <https://github.com/allenai/satlas-super-resolution>. Cenas Sentinel-2 (produto TCI) obtidas do Copernicus Data Space Ecosystem (<https://dataspace.copernicus.eu>); os rasters não são redistribuídos, mas a proveniência permite o redownload.

B. Consistência sob deslocamento

A Tabela I e a Fig. 1 resumem o resultado central. No controle ($\Delta = 0$) a discordância é nula (scPSNR ≈ 100 dB, SSIM = 1,000), validando o protocolo. Para qualquer deslocamento, porém, as duas saídas *divergem*, e a divergência cresce de forma monotônica à medida que a sobreposição encolhe — ou seja, à medida que a região comparada se aproxima das bordas dos tiles. Entre 90% e 3% de sobreposição, o scPSNR cai de 30,8 para 24,7 dB e o SSIM de 0,85 para 0,45, com o MAE subindo de 5,0 para 12,4 DN. O comportamento é **consistente entre as 57 regiões**: a dispersão do scPSNR fica em torno de $\pm 1,2$ dB em todas as faixas de sobreposição, indicando que o achado é robusto e não um artefato de uma área específica. Nota-se que mesmo a 90% de sobreposição (região predominantemente interior) a coincidência *não* é perfeita, coerente com a inexistência de interior limpo quando o campo receptivo excede o tile. **O gerador não é invariante a translação.**

Tabela I
SHIFT-CONSISTENCY VS SOBREPOSIÇÃO (SENTINEL-2, $N = 8$; *pooled*, MÉDIA ENTRE 57 REGIÕES)

Overlap	scPSNR $\uparrow$	SSIM $\uparrow$	MAE $\downarrow$	RMSE $\downarrow$
100,0% (controle)	99,99	1,000	0,00	0,00
90,6%	30,83	0,850	5,03	7,88
81,2%	29,91	0,819	5,83	8,76
68,8%	28,94	0,780	6,76	9,79
59,4%	28,35	0,753	7,38	10,50
50,0%	27,81	0,722	7,99	11,20
40,6%	27,24	0,685	8,68	12,00
31,2%	26,65	0,642	9,44	12,88
18,8%	25,78	0,568	10,64	14,31
9,4%	25,09	0,505	11,67	15,57
3,1%	24,65	0,452	12,40	16,43




Figura 1. Consistência sob deslocamento (*pooled*, 57 regiões). scPSNR (azul) e SSIM (vermelho) em função da sobreposição, com a faixa de dispersão entre regiões. A queda monotônica ao reduzir a sobreposição revela a não-invariância; o salto a 100% corresponde ao controle $\Delta = 0$.

C. Onde a não-invariância se concentra

A Fig. 2 mostra o perfil $P(d)$ *pooled* (média entre as 57 regiões): a diferença absoluta média é máxima *na borda* do tile ($\sim 10,1$ DN em $d = 0$) e *decai monotonicamente* para o interior, chegando a $\sim 2,0$ DN a ~ 50 px de profundidade. Esse é o diagnóstico que liga o achado à teoria: como cada pixel de saída integra o *zero-padding* da borda através de um campo receptivo que excede o tile, o erro de equivariância é introduzido na borda e se atenua à medida que a influência relativa do *padding* diminui. O perfil é, portanto, simultaneamente a *explicação* do fenômeno e o *insumo* para a máscara de junção ótima.




Figura 2. Perfil de erro vs distância à borda de tile mais próxima (px HR), *pooled* (57 regiões). A diferença média decai de $\sim 10,1$ DN na borda para $\sim 2,0$ DN no interior, localizando a não-invariância junto ao *zero-padding*.

D. Comparação de blends

A Tabela II e a Fig. 3 comparam as estratégias de junção (*pooled*, média entre as 57 regiões). Sem qualquer *blend* (*none*), a costura é nítida: *seam_excess* = 1,30 (excesso de $\sim 30\%$ de gradiente nas junções) e PSNR de referência de apenas 25,3 dB — a manifestação direta do erro de borda diagnosticado acima. Qualquer ponderação já reduz drasticamente a costura, e entre as estratégias clássicas a melhor é a **gaussiana**, que quase elimina a costura (*seam_excess* = 1,05) e lidera a fidelidade (PSNR 34,4 dB, SSIM 0,959). Notavelmente, a máscara *data-driven* crua (1,09 / 32,4 dB) *não* superou a gaussiana: embora principiada, o perfil empírico carrega ruído de amostragem, ao passo que o decaimento suave do peso gaussiano casa bem com a forma do perfil de erro da Fig. 2. É um resultado honesto que sugere regularizar/parametrizar o perfil antes de usá-lo como máscara — o que motiva as variantes exploratórias da Tabela III. O *ranking* de blends é estável entre regiões (desvio-padrão do *seam_excess* $\sim 0,04$ em todas as estratégias).

E. Discussão

Os três resultados são coerentes entre si e confirmam a hipótese. (i) A **não-invariância é real e mensurável**: a auto-

Tabela II
MÉTRICAS POR ESTRATÉGIA DE BLEND (*pooled*, MÉDIA ENTRE 57 REGIÕES)

Blend	seam_excess→ 1	PSNR_ref↑	SSIM_ref↑
none	1,303	25,26	0,697
linear	1,099	32,03	0,923
cosine	1,072	33,33	0,945
gaussian	1,047	34,38	0,959
data-driven	1,093	32,41	0,928




Figura 3. Visibilidade de costura (*seam_excess*) por estratégia de blend (*pooled*, 57 regiões); a linha tracejada marca o ideal (1,0). *none* é o pior; *gaussian* é o mais próximo do ideal entre as clássicas.

consistência degrada monotonicamente com a aproximação às bordas (Tabela I). (ii) Sua **causa é localizada**: o perfil de borda (Fig. 2) mostra que o erro nasce no *zero-padding* e se propaga pelo campo receptivo excessivo, exatamente como a teoria de equivariância de CNNs prevê [4]. (iii) Há um **trade-off de junção** bem comportado: ponderar a sobreposição troca um pouco de nitidez por continuidade, e entre as clássicas o ponto de operação gaussiano domina tanto a costura quanto a fidelidade. Os três achados se reproduzem com baixa dispersão nas **57 regiões**, o que os qualifica como propriedades do gerador, e não de uma área específica. Na prática, recomenda-se montar mosaicos com *sobreposição não-nula entre tiles* e *feathering gaussiano*, descartando as bordas onde o erro de equivariância é máximo; uma sobreposição que cubra a faixa de $\sim 15\text{--}20$ px HR de maior erro já remove a quase totalidade da costura.

F. Estratégias adicionais de junção (exploratório)

A constatação de que a máscara *data-driven* crua perde para a gaussiana por *ruído* de amostragem motiva variantes adicionais, avaliadas com o mesmo protocolo nas **57 regiões** (Tabela III). (i) **Data-driven suavizado**: ajustando um perfil monótono e suave a $P(d)$ antes de derivar o peso $\propto 1/\hat{P}(d)$, a máscara guiada por dados passa a *superar* a gaussiana em *todos* os eixos (*seam_excess* 1,028 vs 1,047; PSNR 34,85

vs 34,38 dB; SSIM 0,964 vs 0,959) e exibe o **maior** PSNR entre todas as estratégias — a desvantagem anterior do *data cru* (1,093) era de ruído, não de princípio. (ii) **Domínio de gradiente (Poisson)**: reconstruindo o mosaico a partir de um campo de gradientes sem costura (gradiente tomado sempre do tile mais confiável) e resolvendo a equação de Poisson com condição de *Dirichlet* ancorada ao composto de referência, obtém-se a *menor* costura (*seam_excess* = 0,979, abaixo de 1: a junção fica mais suave que o conteúdo médio) e o **maior** SSIM (0,988); a *Dirichlet* ancora a intensidade e recupera o PSNR para 32,4 dB (a variante de Neumann derivava o tom e caía a ~ 26 dB). (iii) **Shift-ensemble**: promediar inferências em múltiplos deslocamentos inteiros explora a *própria* não-invariância — cada pixel é coberto por tiles em posições relativas distintas, e os artefatos de borda, dependentes da posição, se cancelam — atingindo costura quase ideal (0,999) ao custo de nitidez (PSNR 28,1; melhor avaliado pela *shift-consistency* que por fidelidade a uma referência nítida). Em suma, o gaussiano é superado: *Poisson com Dirichlet* domina costura e estrutura, e o *data-driven suavizado* domina a fidelidade em PSNR.

Tabela III
ESTRATÉGIAS ADICIONAIS VS. REFERÊNCIA (POOLED, 57 REGIÕES; MELHORES EM NEGRITO)

Blend	seam_excess→ 1	PSNR_ref↑	SSIM_ref↑
poisson (Dirichlet)	0,979	32,38	0,988
ensemble	0,999	28,07	0,784
smoothed	1,028	34,85	0,964
gaussian (ref.)	1,047	34,38	0,959
data (cru)	1,093	32,41	0,928

V. CONCLUSÕES

Medimos, em modo *zero-shot* e sobre Sentinel-2, o grau de (não-)invariância a translação do gerador ESRGAN/SSR_RRDBNet do Satlas. Partindo de uma validação de região única, estendemos o protocolo a **57 regiões** e agregamos os resultados de forma *pooled*. O gerador **não** é invariante: a discordância entre inferências deslocadas do mesmo conteúdo cresce de 30,8 para 24,7 dB de scPSNR à medida que a comparação se aproxima das bordas, e o perfil de erro atribui o fenômeno ao *zero-padding* sob um campo receptivo maior que o tile. Para a montagem de mosaicos, entre as estratégias clássicas o *blend* gaussiano reduz o excesso de gradiente nas costuras de 1,30 para 1,05 e eleva o PSNR de referência para 34,4 dB, superando a máscara guiada por dados crua; estratégias adicionais (Poisson com Dirichlet, *data-driven* suavizado) chegam a superá-lo. **Todos os achados se reproduzem com baixa dispersão entre as 57 regiões**, confirmando sua robustez.

Limitações e trabalhos futuros. A validação multi-região realizada (57 áreas geograficamente distintas) confirmou a robustez do decaimento de borda e do *ranking* de blends, com baixa dispersão entre regiões. Quatro direções se abrem. (1)

Junção em domínio de gradiente: consolidar a reconstrução de Poisson com Dirichlet e as máscaras de confiabilidade suavizadas (data-driven regularizado) como sucessoras da gaussiana. **(2) Shift-ensemble** como mitigação em tempo de inferência, avaliada pela própria *shift-consistency* (não só por fidelidade), estudando o trade-off custo×nitidez com o número de deslocamentos. **(3) Anti-aliasing** no gerador (*blur-pool* [4]) para atacar a não-invariância na origem. **(4) Generalização** a outras tiles/biomas, sensores, fatores de escala e arquiteturas de SR, testando a universalidade do efeito de borda. Por fim, o diagnóstico sugere a mitigação direta via *finetuning* com uma perda explícita de consistência de borda entre tiles deslocados,

$$\mathcal{L}_{borda} = \frac{1}{|\mathcal{B}|} \sum_{(i,j) \in \mathcal{B}} \|\nabla I_A^{SR}(i,j) - \nabla I_B^{SR}(i,j)\|_2, \quad (5)$$

que penalizaria diretamente a discordância de gradiente nas junções, tornando o gerador mais próximo da equivariância formal de suas camadas.

REFERÊNCIAS

- [1] X. Wang *et al.*, “ESRGAN: Enhanced super-resolution generative adversarial networks,” in *Proc. ECCV Workshops*, 2018.
- [2] F. Bastani, P. Wolters, R. Gupta, J. Ferdinando, and A. Kembhavi, “SatlasPretrain: A large-scale dataset for remote sensing image understanding,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023, pp. 16772–16782.
- [3] P. Wolters, F. Bastani, and A. Kembhavi, “Zooming out on zooming in: Advancing super-resolution for remote sensing,” *arXiv preprint arXiv:2311.18082*, 2023. [Online]. Available: <https://arxiv.org/abs/2311.18082>
- [4] R. Zhang, “Making convolutional networks shift-invariant again,” in *Proc. ICML*, 2019, pp. 7324–7334.
- [5] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image quality assessment: From error visibility to structural similarity,” *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, 2004.
- [6] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, “The unreasonable effectiveness of deep features as a perceptual metric,” in *Proc. CVPR*, 2018.
- [7] Z. Wang, J. Chen, and S. C. H. Hoi, “Deep learning for image super-resolution: A survey,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 10, 2021.